**Estimación del caudal medio diario en cuencas de Colombia**

*MINE-4101 Ciencia de Datos Aplicada. Proyecto, primera entrega*

## 1. Definición de la problemática y entendimiento del negocio

**Organización y contexto.** XM S.A. E.S.P. opera el Sistema Interconectado Nacional (SIN) y administra el Mercado de Energía Mayorista. La planeación de la operación y el despacho dependen de la estimación de los aportes hídricos a los embalses: las plantas hidráulicas representan el 63,4 % de la capacidad efectiva neta del SIN [1]. El área hidrográfica Magdalena-Cauca, la de mayor importancia socioeconómica por su población y su aporte al PIB, tiene el menor rendimiento hídrico del país: 30,9 L/s·km², frente a 113,0 L/s·km² en el Pacífico [2]. El país ha vivido los dos extremos del régimen hidrológico. La Niña 2010–2011 dejó 3,2 millones de personas damnificadas o afectadas y daños por 11,2 billones de pesos [3], y el IDEAM estima en 75 % la probabilidad de que el fenómeno de El Niño en curso sea el más fuerte registrado [4].

**Problemática y justificación.** La red de estaciones de aforo no cubre todas las cuencas del país, y donde no hay estación no existen series diarias de caudal. Las decisiones de operación de embalses, despacho y gestión del riesgo se toman sin información de esa parte del territorio. El aprendizaje profundo ha estimado caudal en cuencas no aforadas, pero la evidencia proviene de regímenes templados o dominados por nieve [5], y en Colombia no se ha evaluado un modelo regional que agrupe cuencas de todo el territorio. El conjunto CAMELS-COL, con 346 cuencas y hasta 42 años de registros diarios (1981–2022) [6], [7], permite hacer esa evaluación. El alcance es la estimación del caudal a partir de la meteorología observada; el pronóstico queda como trabajo futuro.

**Objetivo general:** diseñar y construir un producto de datos que estime el caudal medio diario de cuencas colombianas, incluidas cuencas sin estación de aforo, para apoyar la operación de embalses, el despacho energético y la gestión del riesgo por crecientes. Objetivos específicos: (1) definir la problemática, los usuarios, los KPIs y los requerimientos del producto; (2) documentar y explorar las 346 cuencas con un reporte de calidad y suficiencia de datos por región; (3) entrenar y comparar una regresión lineal, un Random Forest y una red LSTM (Long Short-Term Memory) regional; (4) construir un prototipo con modelo, API REST y aplicación web.

**Tabla 1.** Indicadores clave de desempeño (KPIs). NSE: eficiencia de Nash-Sutcliffe; KGE: eficiencia de Kling-Gupta.

| KPI | Decisión de negocio que apoya | Meta |
|---|---|---|
| NSE y KGE medianos en el periodo de prueba (2016–2022) | Confiabilidad para operar embalses | ≥ 0,70 |
| NSE mediano en cuencas no vistas, también por región | Utilidad en zonas sin estación | ≥ 0,50 |
| Cuencas en que el mejor modelo supera en NSE a la regresión lineal | Valor agregado del modelo | ≥ 70 %, mejora mediana ≥ 0,10 |
| Recall en días sobre el percentil 95, con precisión como control | Gestión del riesgo por crecientes | Recall ≥ 0,70; precisión ≥ 0,50 |
| Cuencas procesadas | Alcance regional | 346 de 346 |

## 2. Ideación del producto de datos

Caudal-COL será una aplicación para consultar el caudal medio diario estimado de cada cuenca, junto con la serie observada, las métricas de desempeño y la calidad de los datos. Tendrá tres componentes: (i) un modelo de machine learning (LSTM regional, con regresión lineal y Random Forest como referencia), entrenado fuera de línea; (ii) una API REST (FastAPI) que entrega estimaciones, métricas y calidad por cuenca; y (iii) una aplicación web (Streamlit) con mapa, series, indicadores y descarga de datos, desplegada en un contenedor Docker.

**Tabla 2.** Usuarios, procesos actuales y dolores.

| Usuario | Proceso actual | Dolores |
|---|---|---|
| Analista de planeación y operación de XM (principal) | Construye escenarios de aportes hídricos a los embalses con series históricas de caudal. | Afluentes sin estación; registros con vacíos; estimaciones sin medida de confiabilidad. |
| Operador de embalses de una generadora | Define descargas y generación según los aportes esperados. | Desconoce los aportes de subcuencas no instrumentadas. |
| Profesional de gestión del riesgo | Identifica zonas expuestas a crecientes y prioriza intervenciones. | Sin series de caudal en cuencas pequeñas sin estación. |
| Hidrólogo (IDEAM, consultoras) | Completa series y calibra modelos cuenca por cuenca. | La calibración individual es costosa y requiere caudal observado. |

Requerimientos indispensables: consultar una cuenca en el mapa o por código con su serie estimada y observada, verla como si no tuviera estación, y ver sus métricas (NSE, KGE, RMSE, MAE) y la calidad del registro. Importantes: comparar modelos, identificar días sobre el percentil 95 y descargar en CSV. Fuera del alcance: el pronóstico. No funcionales: sin fuga de información, reproducible, respuesta menor a 3 s e interfaz en español. Los dolores de la Tabla 2 se validarán con entrevistas a usuarios. La Figura 1 muestra el mockup.




**Figura 1.** Mockup de la pantalla principal. Los valores (x,xx) y la gráfica son marcadores de posición.

## 3. Aspectos éticos y legales

El proyecto no usa datos personales, pero sus estimaciones pueden alimentar decisiones con efectos sobre personas. El punto legal más relevante es la licencia: CAMELS-COL se publica con licencia CC BY 4.0 [6], la precipitación de CHIRPS es de dominio público [8] y el caudal del IDEAM es información pública [9]; en cambio, la temperatura y la evapotranspiración provienen de MSWX, con licencia CC BY-NC 4.0, que restringe el uso comercial [10]. El uso académico está cubierto, pero la adopción

por XM o una generadora requiere autorización de los autores de MSWX o sustituir esa fuente y reentrenar el modelo. La Tabla 3 resume los demás aspectos.

**Tabla 3.** Aspectos éticos y legales, riesgo y manejo.

| Aspecto | Riesgo y manejo |
|---|---|
| Privacidad y confidencialidad | Sin datos personales ni internos de empresas; si la aplicación registra usuarios, política de tratamiento de datos según la Ley 1581 de 2012 [11]. |
| Transparencia | Cada estimación se muestra con NSE, KGE y avisos de calidad; código y datos públicos, en línea con la Política Nacional de IA [12]. |
| Sesgo regional | El 53 % de las cuencas está en Magdalena-Cauca; las métricas se reportan por región para no ocultar un menor desempeño en Amazonas y Pacífico. |
| Responsabilidad | Herramienta de apoyo: la decisión es de un analista. Las alertas por crecientes son competencia del IDEAM y del sistema de la Ley 1523 de 2012 [13]. |
| Regulación | El despacho se rige por la Ley 143 de 1994 [14] y la regulación de la CREG; un uso oficial requiere validación previa. |

## 4. Enfoque analítico

Cada pregunta de negocio tiene una prueba y un criterio de decisión con $\alpha = 0,05$ (Tabla 4), y cada resultado se reporta con el tamaño del efecto y su IC del 95 % para separar la significancia estadística de la relevancia práctica. P1 a P3 se responden en la Sección 6; P4 a P9, con los modelos.

**Tabla 4.** Preguntas de negocio, prueba y criterio de decisión.

| ID | Pregunta de negocio | Prueba | Criterio |
|---|---|---|---|
| P1 | ¿Magdalena-Cauca tiene menor oferta hídrica que el resto del país? | t-test de Welch unilateral | $p < 0,05$ |
| P2 | ¿La suficiencia del registro (< 5 % de días faltantes) depende de la región? | Chi-cuadrado de independencia | $p < 0,05$ |
| P3 | ¿Qué atributos de cuenca se asocian con el caudal? | Correlación de Spearman y PCA | $p < 0,05$ y $\lvert\rho\rvert \geq 0,3$ |
| P4 | ¿La estimación es confiable para operar? | NSE y KGE por cuenca | Mediana ≥ 0,70 |
| P5 | ¿El LSTM agrega valor frente a la regresión lineal y el Random Forest? | t-test pareado sobre el NSE por cuenca | $p < 0,05$ y mejora ≥ 0,10 |
| P6 | ¿El modelo sirve en cuencas sin estación? | Validación cruzada espacial | NSE mediano ≥ 0,50 |
| P7 | ¿El desempeño es igual en todas las regiones? | ANOVA y chi-cuadrado | $p < 0,05$ |
| P8 | ¿La lluvia satelital limita el desempeño (cuencas con coeficiente de escorrentía > 1)? | t-test de Welch | $p < 0,05$ |
| P9 | ¿El modelo identifica los días de creciente? | Recall y precisión sobre el percentil 95 | Recall ≥ 0,70; precisión ≥ 0,50 |

Técnicas: análisis de calidad (completitud, consistencia, unicidad, atípicos por rango intercuartílico); estadística descriptiva, histogramas, diagramas de caja y mapas; correlación de Spearman y PCA; pruebas t, ANOVA y chi-cuadrado; y como modelos, regresión lineal y Random Forest con precipitación acumulada a 1, 7, 30 y 90 días, y un LSTM regional con ventanas de 365 días de forzantes y atributos estáticos [15]. La validación combina una partición temporal (entrenamiento 1981–2010, validación 2011–2015, prueba 2016–2022) y una validación cruzada espacial de 5 particiones por sistemas de ríos completos, sin cuencas conectadas entre entrenamiento y evaluación [16]. Métricas por cuenca: NSE [17], KGE [18], RMSE y MAE en mm/día, resumidas con la mediana nacional y por región, y recall y precisión en los días de creciente.

## 5. Recolección de datos

La fuente es CAMELS-COL versión 3, descargado de Zenodo [6] y documentado en su artículo de datos [7]. Integra caudal observado del IDEAM, precipitación de CHIRPS, temperatura y evapotranspiración potencial de MSWX, y atributos derivados del IGAC, el Servicio Geológico Colombiano y MapBiomas. Todos los archivos se unen por gauge_id, el código IDEAM de la estación (Tabla 5). El diccionario de datos, con la definición, unidad e interpretación de las 79 variables de atributos y de las columnas de las series, está en el archivo diccionario_datos.md del repositorio.

**Tabla 5.** Fuentes de datos, estructura e importancia.

| Fuente | Estructura | Variables principales | Importancia |
|---|---|---|---|
| Series diarias (04) | 346 archivos de texto, una fila por día, 1981–2022 | Caudal ($m^3/s$), precipitación y evapotranspiración (mm/día), temperaturas (°C) | Objetivo y forzantes del modelo |
| Información de estaciones (02) | Tabla, una fila por cuenca | Departamento, coordenadas, periodo de registro, % de días faltantes | Suficiencia del registro |
| Atributos estáticos (05–08, 10, 11) | Seis tablas, una fila por cuenca, 60 variables | Área, elevación, número de curva, aridez, cobertura, suelos, geología | Transferir el modelo a cuencas nuevas |
| Firmas hidrológicas (09) | Tabla, una fila por cuenca, 11 variables | Caudal específico, coeficiente de escorrentía, flujo base | Solo exploración: causarían fuga |
| Capas espaciales (03, 12, 13) | Shapefiles y rasters | Límites de cuenca, red de drenaje, humedad topográfica | Mapas |

## 6. Entendimiento de los datos

**Calidad.** La calidad se evaluó por dimensión sobre los 4.072.868 registros diarios y las 8 tablas de atributos (Tabla 6). El hallazgo principal es que las series no tienen celdas vacías, pero los días sin dato no aparecen como filas: hay 18.281 vacíos de fechas, el 80,6 % de los días faltantes está en vacíos de más de 30 días y 148 cuencas tienen al menos un vacío de un año o más (máximo 1.747 días).

**Tabla 6.** Hallazgos de calidad y tratamiento.

| Dimensión | Hallazgo | Tratamiento |
|---|---|---|
| Completitud | Atributos: 8 tablas, 346 cuencas, sin nulos. Series: vacíos de fechas descritos arriba. | Reindexar a calendario diario; interpolar forzantes solo en vacíos ≤ 7 días; excluir ventanas con vacíos largos |
| Suficiencia | 252 cuencas tienen al menos un año en 2016–2022; 92 no tienen datos en ese periodo. | Evaluación temporal sobre 252 cuencas |
| Validez | Sin fechas duplicadas, sin valores negativos y sin temperatura mínima mayor que la máxima. 228 días con caudal cero en 29 cuencas. | Conservar: el caudal cero es posible en ríos intermitentes |
| Consistencia | El número de registros y el % de faltantes del archivo 02 coinciden con las series. Los porcentajes de geología suman entre 8,7 % y 200 %; los de cobertura, 100 %. | Usar las series como referencia; reportar la geología sin forzar la suma |
| Unicidad | La roca volcanoclástica duplica a la volcánica ($\rho$ = 1,0). | Eliminar una de las dos |
| Conformidad | Separadores distintos, codificación Latin-1, código de estación decimal, coordenadas en metros y 16.037 filas vacías en el archivo 11. | Normalizar en la carga |

| Dimensión | Hallazgo | Tratamiento |
|---|---|---|
| Precisión | 55 cuencas con coeficiente de escorrentía > 1 (máximo 14,45); 13.219 días con evapotranspiración > 15 mm/día (máximo 20,1); una cuenca con duración media de crecientes de 691 días. | Marcar como atípicos; analizar en P8 y revisar con la fuente antes de modelar |

**Análisis univariado.** El área va de 25 a 260.372 km² (mediana 777 km²), una distribución muy asimétrica que se analiza en escala logarítmica. El registro tiene una mediana de 35,9 años (entre 11,4 y 41,9) y el caudal específico, una mediana de 3,27 mm/día. El 53 % de las cuencas está en Magdalena-Cauca (182), frente a 57 en Orinoco, 53 en Caribe, 32 en Pacífico y 22 en Amazonas. La aridez supera 1 en 309 cuencas, coherente con la clasificación subhúmeda y semiárida del artículo del conjunto [7].

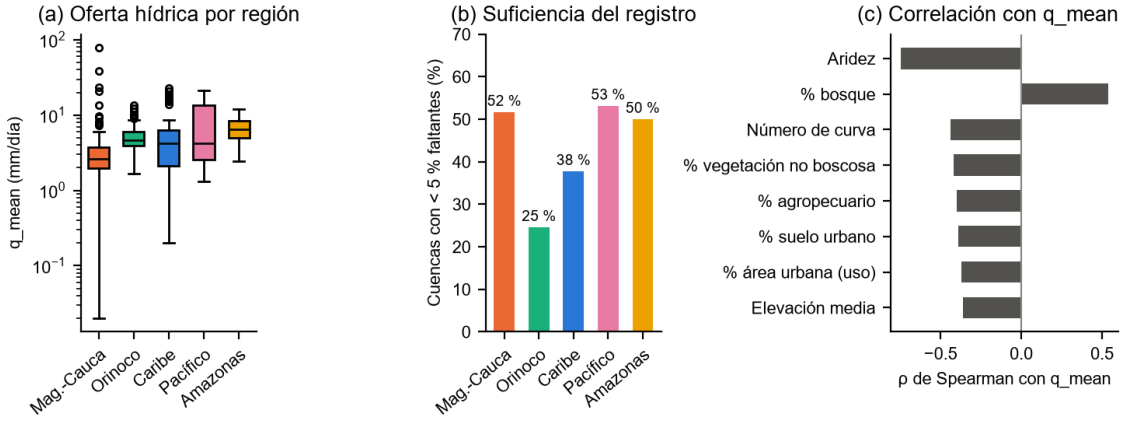



**Figura 2.** (a) Caudal específico por región, escala logarítmica. (b) Porcentaje de cuencas con menos de 5 % de días faltantes. (c) Atributos con |ρ| ≥ 0,3.

**Análisis bivariado y multivariado.** P1: el caudal específico medio de Magdalena-Cauca es 3,70 mm/día, frente a 6,15 en el resto del país (diferencia −2,45; IC 95 %: −3,67 a −1,23; t de Welch = −3,95; p < 0,001). El resultado no depende de valores extremos: se mantiene en escala logarítmica (medias geométricas de 2,35 y 4,70 mm/día; p < 0,001) y al excluir los 34 atípicos por rango intercuartílico (p < 0,001). Se rechaza H0: los datos confirman la menor oferta hídrica de la región que concentra la demanda (Figura 2a). P2: la suficiencia del registro depende de la región ($\chi^2$ = 15,07; 4 g.l.; p = 0,005); solo el 25 % de las cuencas del Orinoco tiene menos de 5 % de días faltantes, frente a 53 % en el Pacífico (Figura 2b). P3: 11 de 58 atributos tienen |ρ| ≥ 0,3 con el caudal, y los 11 siguen siendo significativos con corrección de Bonferroni (α = 0,00086). Se usó Spearman porque trabaja con rangos y no lo mueven valores extremos como el coeficiente de escorrentía de 14,45. La aridez (ρ = −0,74) indica que, cuando la demanda evaporativa supera a la lluvia, queda menos agua para escurrir; el bosque (0,54) se asocia con las cuencas más húmedas; el número de curva (−0,44) y las coberturas agropecuaria y urbana (−0,40 y −0,39) se concentran en las cuencas más secas e intervenidas del Magdalena-Cauca (Figura 2c). Son asociaciones, no relaciones causales. El PCA muestra que la información está repartida: el primer componente explica el 20 % de la varianza y se requieren 19 para el 80 %, por lo que los atributos aportan información complementaria. Como muchas cuencas están

anidadas, la independencia se cumple solo en parte; por eso los valores p se interpretan junto con el tamaño del efecto.

## 7. Conclusiones iniciales

- **Los datos son suficientes para un modelo regional:** 346 cuencas con atributos completos y 252 evaluables en el periodo de prueba.
- **Los vacíos largos de fechas son el principal riesgo de calidad** y definen la preparación de los datos.
- **Magdalena-Cauca tiene la menor oferta hídrica,** lo que respalda el foco de negocio en esa región.
- **La suficiencia de datos es desigual entre regiones** (el Orinoco es la más débil); las métricas se reportarán por región.
- **La aridez y la cobertura se asocian con el caudal,** lo que justifica un modelo basado en atributos.
- **55 cuencas sugieren subestimación de la lluvia satelital,** a evaluar en P8.

Próximos pasos: implementar el pipeline de preparación; entrenar la línea base, el Random Forest y el LSTM; informar a los docentes el uso de técnicas no vistas en clase; validar usuarios y requerimientos con un stakeholder del sector; y aclarar la licencia de MSWX.

## Referencias


[1] XM S.A. E.S.P., “En el primer trimestre del 2025, 17 proyectos nuevos entraron para fortalecer el Sistema Interconectado Nacional,” 28 abr. 2025. Disponible: https://www.xm.com.co/noticias/7831

[2] IDEAM, Estudio Nacional del Agua 2022. Bogotá, Colombia: Instituto de Hidrología, Meteorología y Estudios Ambientales, 2023.

[3] CEPAL y BID, Valoración de daños y pérdidas: Ola invernal en Colombia, 2010–2011. Bogotá, Colombia: Naciones Unidas, 2012, LC/BOG/L.23.

[4] IDEAM, “El Niño se fortalece: aumenta a 75 % la probabilidad de que sea el más fuerte de la historia,” Comunicado Especial No. 100, 10 sep. 2026.

[5] M. He et al., “Streamflow prediction in ungauged catchments through use of catchment classification and deep learning,” J. Hydrol., vol. 639, art. 131638, 2024.

[6] D. A. Jimenez et al., “CAMELS-COL: A large-sample hydrometeorological dataset for Colombia,” Zenodo, v3, 2026, doi: 10.5281/zenodo.18794895.

[7] D. A. Jimenez et al., “CAMELS-COL: A large-sample hydrometeorological dataset for Colombia,” Earth Syst. Sci. Data Discuss. [preprint], essd-2025-200, 2025.

[8] C. Funk et al., “The climate hazards infrared precipitation with stations: a new environmental record for monitoring extremes,” Sci. Data, vol. 2, art. 150066, 2015.

[9] Congreso de la República de Colombia, Ley 1712 de 2014, Ley de Transparencia y del Derecho de Acceso a la Información Pública.

[10] H. E. Beck et al., “MSWX: Global 3-hourly 0.1° bias-corrected meteorological data with near real-time updates and forecast ensembles,” Bull. Amer. Meteor. Soc., vol. 103, pp. E710–E732, 2022.

[11] Congreso de la República de Colombia, Ley 1581 de 2012, disposiciones generales para la protección de datos personales.

[12] Consejo Nacional de Política Económica y Social, Documento CONPES 4144: Política Nacional de Inteligencia Artificial. Bogotá: DNP, 2025.

[13] Congreso de la República de Colombia, Ley 1523 de 2012, política nacional de gestión del riesgo de desastres.

[14] Congreso de la República de Colombia, Ley 143 de 1994, régimen de la electricidad.

[15] F. Kratzert et al., “Towards learning universal, regional, and local hydrological behaviors via machine learning applied to large-sample datasets,” Hydrol. Earth Syst. Sci., vol. 23, pp. 5089–5110, 2019.

[16] F. Kratzert et al., “Toward improved predictions in ungauged basins: Exploiting the power of machine learning,” Water Resour. Res., vol. 55, no. 12, pp. 11344–11354, 2019.

[17] J. E. Nash y J. V. Sutcliffe, “River flow forecasting through conceptual models part I,” J. Hydrol., vol. 10, no. 3, pp. 282–290, 1970.

[18] H. V. Gupta et al., “Decomposition of the mean squared error and NSE performance criteria,” J. Hydrol., vol. 377, no. 1–2, pp. 80–91, 2009.